

FACULDADE DE ENGENHARIA DE COMPUTAÇÃO

PROJETO FINAL I e II

PLANO DE TRABALHO

SFAnalytics

Lucas Carvalho Roncoroni

Edmar Roberto Santana de Rezende

15/04/2017

INTRODUÇÃO

Atualmente, 32% dos computadores no mundo estão infectados por algum tipo de malware (TopTenReviews, 2014).

A identificação de um malware, ou programa malicioso, na maioria dos casos, é feita por um antivírus. Os antivírus trabalham com um sistema de detecção por assinatura.

O que é uma assinatura? Uma assinatura é uma sequência de bytes que identifica um malware. Para gerar uma assinatura é necessário que um programa suspeito tenha sido classificado como malware.

A forma mais comum de determinar se um programa sem nenhuma assinatura é ou não um malware, é verificando sua funcionalidade, através de uma análise de dados. Para tanto utilizam-se certos parâmetros, como código fonte, strings encontradas, dlls usadas, uso de memória, dentre outros, extraídos através de ferramentas específicas para essa finalidade. Para o analista, que se proponha a tal tarefa, é essencial justificar a classificação encontrada.

Outra forma habitual de se realizar essa identificação é através da utilização de técnicas de aprendizagem de máquina, onde com uma base inicial, torna-se possível a classificação de novos programas. O problema com essa abordagem é que o analista fica sem saber como foi feita a classificação, não conseguindo justificar o resultado. Por isso essa abordagem é pouco utilizada.

CARACTERIZAÇÃO DE PROBLEMAS E OBJETIVO (S)

Quase um milhão de malwares são criados todos os dias (CNN, 2015), hackers estão custando entre U\$345 e U\$545 bilhões anualmente para usuários e empresas (U.S. News, 2014). Por isso o desenvolvimento de ferramentas que ajudem um analista a identificar novas ameaças é de extrema importância.

Devido a esse cenário, urge que se desenvolvam ferramentas mais simples que auxiliem o analista em seu trabalho de detecção de novas ameaças. Seria interessante uma ferramenta com a utilização de uma interface gráfica, além de possibilitar o uso da classificação com aprendizado de máquina.

Sendo assim este trabalho propõe a elaboração de um artefato que extraia parâmetros de um programa suspeito, através da análise estática, apresente os parâmetros extraídos utilizando uma interface gráfica, e mostre como foi feita a classificação do programa pelo algoritmo de aprendizagem de máquina.

PLANO DE AVALIAÇÃO DO TRABALHO

Será feita a aprendizagem com malwares para treino; após o treino, alguns especialistas farão a análise de um malware utilizando o artefato proposto. Após classificarem o malware, eles irão responder a um questionário de avaliação da ferramenta.

O trabalho será bem-sucedido, se a avaliação dos especialistas sobre a ferramenta, utilizando o questionário for positiva.

PROPOSTA DO ARTEFATO

O artefato deste trabalho consiste em um classificador de arquivos em maliciosos ou não através de aprendizado supervisionado de máquina com a frequência de cada instrução do código objeto, dlls utilizadas pelo programa e strings dentro do programa.

O diagrama de arquitetura do artefato é apresentado na Figura 1.

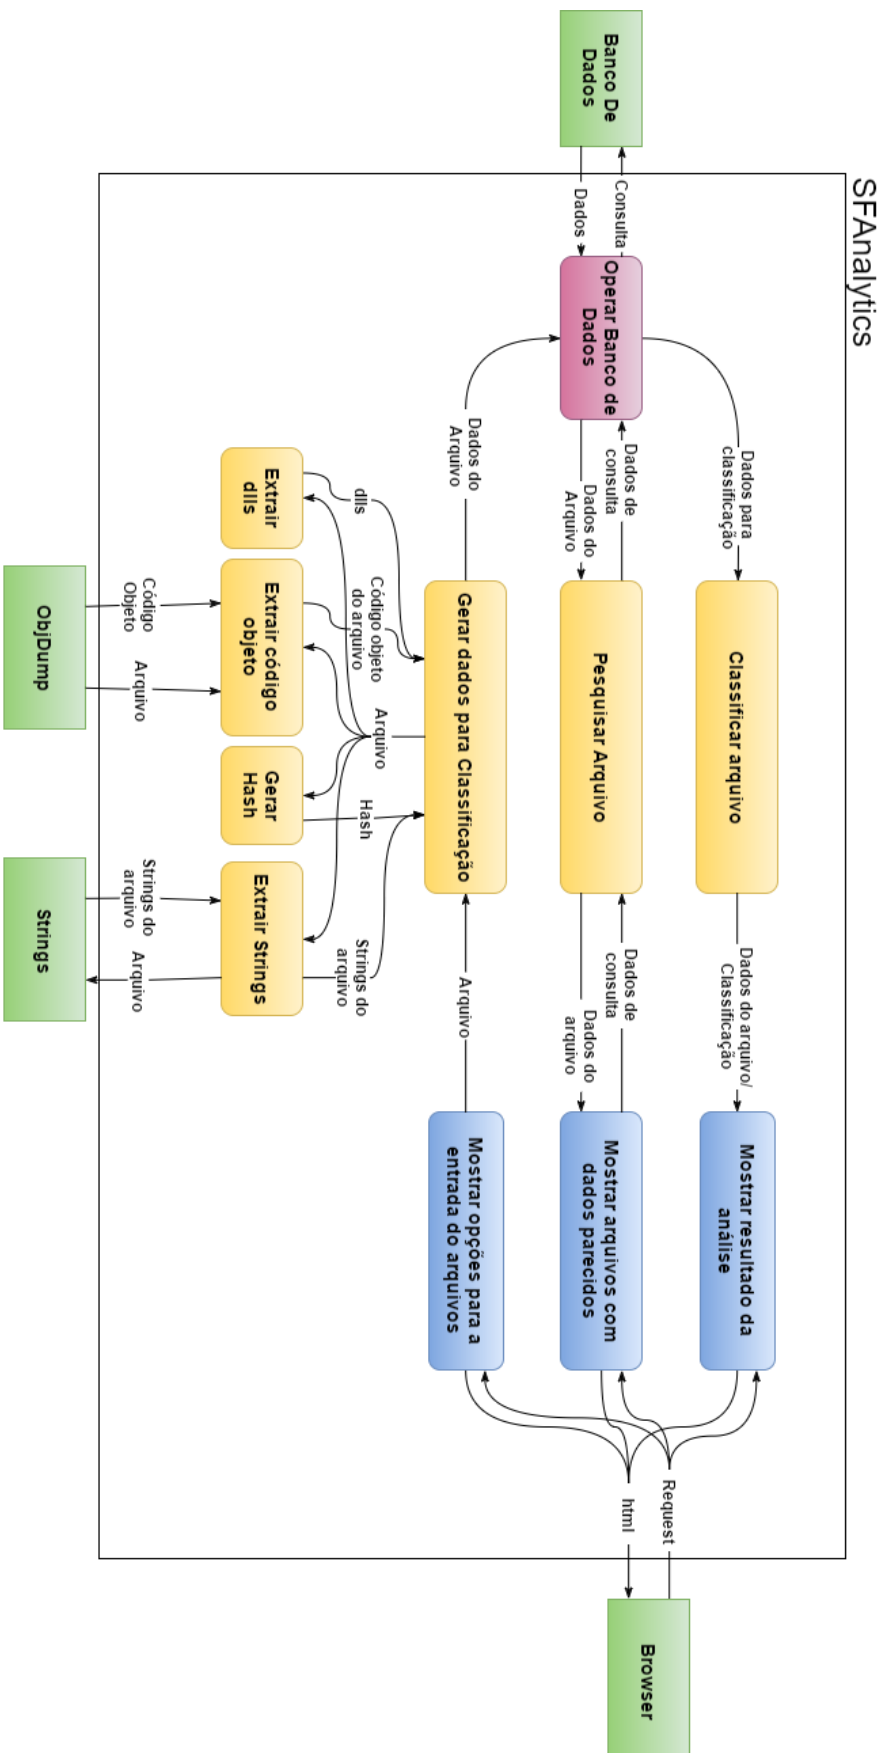


Figura 1. Diagrama de Arquitetura.

TRABALHOS RELACIONADOS

| Trabalho | Análise estática | Análise dinâmica | Interface gráfica | Aprendizado de máquina | Descrições em alto nível |
|-------------|------------------|------------------|-------------------|------------------------|--------------------------|
| VxStream | X | X | X | | X |
| Malwr | X | X | X | | |
| SFAnalytics | X | | X | X | X |

MÉTODO DE DESENVOLVIMENTO

O método escolhido foi o Scrum, pois é um método bem flexível, os Sprints são definidos durante o projeto, e o que é feito em cada Sprint varia conforme as necessidades do cliente.

CRONOGRAMA

| Identificação da Atividade | Descrição | Duração | |
|----------------------------|---|----------|----------|
| | | Início | Fim |
| A1 | Gerenciar o TCC | 23/2/15 | 07/12/15 |
| A2 | Definição do projeto | 23/02/17 | 24/03/17 |
| A3 | Definição das tecnologias utilizadas no projeto | 07/03/17 | 31/03/17 |
| A4 | Definição dos dados utilizados para AM | 07/03/17 | 31/03/17 |
| A5 | Realização do diagrama de arquitetura | 22/03/17 | 24/05/17 |
| A6 | Realização do plano de trabalho | 22/03/17 | 16/06/17 |
| A7 | Realização do diagrama de fluxo de dados | 22/03/17 | 10/04/17 |
| A8 | Realização do diagrama de classes | 25/03/17 | 19/04/17 |
| A9 | Implementação do artefato | 03/04/17 | 13/10/17 |
| A10 | Validação com o cliente da GUI | 12/04/17 | 29/05/17 |
| A11 | Montagem da Base de Dados | 12/06/17 | 30/06/17 |
| A12 | Definição do algoritmo de aprendizagem | 03/07/17 | 16/08/17 |
| A13 | Inserção do algoritmo de aprendizagem | 03/07/17 | 16/08/17 |
| A14 | Avaliar e Validar o Trabalho | 18/08/17 | 18/10/17 |
| A15 | Escrever monografia | 10/10/17 | 27/11/17 |
| A16 | Preparar defesa do TCC | 10/10/17 | 27/11/17 |

DISTRIBUIÇÃO DE ATIVIDADES

| Identificação da Atividade | Primeiro Semestre | | | | | | | | | | | | | | | | | | | | | |
|-------------------------------|-------------------|--|--|---|-----|---|---|---|---|-----|---|---|----|-----|----|----|----|-----|----|----|----|----|
| | Mês/Semana | | | | | | | | | | | | | | | | | | | | | |
| | Fev | | | | Mar | | | | | Abr | | | | Mai | | | | Jun | | | | |
| | | | | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 | 15 | 16 | 17 | 18 | 19 |
| A1 | | | | X | X | X | X | X | X | X | X | X | X | X | X | X | X | X | X | X | X | X |
| A2 | | | | X | X | X | X | X | | | | | | | | | | | | | | |
| A3 | | | | | | X | X | X | X | | | | | | | | | | | | | |
| A4 | | | | | | | | X | X | X | | | | | | | | | | | | |
| A5 | | | | | | | | X | X | X | X | X | X | X | X | X | | | | | | |
| A6 | | | | | | | | X | X | X | X | X | X | X | X | X | X | X | X | | | |
| A7 | | | | | | | | X | X | X | X | | | | | | | | | | | |
| A8 | | | | | | | | X | X | X | X | X | | | | | | | | | | |
| A9 | | | | | | | | | | X | X | X | X | X | X | X | X | X | X | X | X | X |
| A10 | | | | | | | | | | | X | X | X | X | X | X | X | | | | | |
| A11 | | | | | | | | | | | | | | | | | | X | X | X | X | X |

| | | | | | | | | | | | | | | | | | | | | | | |
|-----|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|---|---|---|---|---|
| A12 | | | | | | | | | | | | | | | | | | X | X | X | X | X |
| A13 | | | | | | | | | | | | | | | | | | | | | | |
| A14 | | | | | | | | | | | | | | | | | | | | | | |
| A15 | | | | | | | | | | | | | | | | | | | | | | |
| A16 | | | | | | | | | | | | | | | | | | | | | | |

| Identificação da Atividade | Segundo Semestre Mês/Semana | | | | | | | | | | | | | | | | | | | | | | |
|----------------------------|--------------------------------|----|----|----|-----|----|----|----|-----|----|----|----|-----|----|----|----|-----|----|----|----|----|--|--|
| | Jul | | | | Ago | | | | Set | | | | Out | | | | Nov | | | | | | |
| | 20 | 21 | 22 | 23 | 24 | 25 | 26 | 27 | 28 | 29 | 30 | 31 | 32 | 33 | 34 | 35 | 36 | 37 | 38 | 39 | 40 | | |
| A1 | X | X | X | X | X | X | X | X | X | X | X | X | X | X | X | X | X | X | X | X | X | | |
| A2 | | | | | | | | | | | | | | | | | | | | | | | |
| A3 | | | | | | | | | | | | | | | | | | | | | | | |
| A4 | | | | | | | | | | | | | | | | | | | | | | | |
| A5 | | | | | | | | | | | | | | | | | | | | | | | |
| A6 | | | | | | | | | | | | | | | | | | | | | | | |
| A7 | | | | | | | | | | | | | | | | | | | | | | | |
| A8 | | | | | | | | | | | | | | | | | | | | | | | |
| A9 | X | X | X | X | X | X | X | X | X | X | X | X | X | X | X | | | | | | | | |
| A10 | | | | | | | | | | | | | | | | | | | | | | | |
| A11 | | | | | | | | | | | | | | | | | | | | | | | |
| A12 | X | X | X | X | | | | | | | | | | | | | | | | | | | |
| A13 | X | X | X | X | X | X | X | | | | | | | | | | | | | | | | |
| A14 | | | | | | | X | X | X | X | X | X | X | X | X | X | | | | | | | |
| A15 | | | | | | | | | | | | | | X | X | X | X | X | X | X | X | | |
| A16 | | | | | | | | | | | | | | X | X | X | X | X | X | X | X | | |

RESULTADOS ESPERADOS

| Identificação do Resultado | Descrição | Identificação da Atividade |
|----------------------------|----------------------------|----------------------------|
| R1 | Plano de trabalho | A1 |
| R2 | Relatório de Atividades | A2 |
| R3 | Diagrama de fluxo de dados | A3 |
| R4 | Diagrama de classes | A4 |
| R5 | Artefato computacional | A5 |
| R6 | Base de dados | A6 |

RECURSOS MATERIAIS

Recursos de hardware:

Notebook.

Recursos de software:

Objdump;

Strings;

Visual Studio.

UTILIZAÇÃO DOS RECURSOS MATERIAIS

| Dia | Segunda-feira | Terça-feira | Quarta-feira | Quinta-feira | Sexta-feira | Sábado | Domingo |
|---------|---------------|-------------|--------------|--------------|-------------|----------|----------|
| Horário | 17h-23h | 17h-23h | 20h-23h | 17h-23h | 17h-23h | 14h-18h | 13h-17h |
| Recurso | Notebook | Notebook | Notebook | Notebook | Notebook | Notebook | Notebook |

GRAU DE DIFICULDADE – ASPECTOS DE INOVAÇÃO E APRIMORAMENTO

| Inovação | Grau de dificuldade |
|---|---------------------|
| <i>Mostrar como foi feita a classificação</i> | Alto |

Mostrar como foi feita a classificação – O artefato deve mostrar o que o algoritmo de aprendizado de máquina aprendeu para fazer a classificação. O grau é alto devido à falta de conhecimento do autor sobre como fazer isso e também interfere na decisão do algoritmo utilizado no projeto.

| Aprimoramento | Grau de dificuldade |
|----------------|---------------------|
| <i>Django</i> | Médio |
| <i>Objdump</i> | Baixo |
| <i>Python</i> | Médio |
| <i>Strings</i> | Baixo |

Django – Framework para a realização do sistema. O grau é médio devido a falta de conhecimento do autor do framework.

Objdump – Ferramenta para extração do código objeto de um executável. O grau é baixo pois a ferramenta não é difícil de ser utilizada, a dificuldade é na criação de uma interface dela com o artefato.

Python – Linguagem de programação utilizada no projeto. O grau é médio pela falta de conhecimento aprofundado do autor nessa linguagem.

Strings – Ferramenta para extração do código objeto de um executável. O grau é baixo pois a ferramenta não é difícil de ser utilizada, a dificuldade é na criação de uma interface dela com o artefato.

ANÁLISE DE RISCOS

| Entrada | Probabilidade | Risco | Alternativa |
|-------------------|---------------|-------|---|
| Base de dados | Baixa | Médio | Gerar base a partir de Malwares de forma automatizada |
| Objdump | Baixa | Leve | Existem outras ferramentas que fazem a mesma coisa. |
| Django | Alta | Médio | Pedir ajuda ao orientador, por ter mais conhecimento sobre o framework. |
| Notebook do autor | Média | Médio | Usar computadores da faculdade para implementar o projeto. |

OUTRAS OBSERVAÇÕES

Para o controle de versionamento e backup tem sido usados o Google Drive e o github.

REFERÊNCIAS

TopTenReviews, *How Infected Are We?* Disponível em:

<<http://www.toptenreviews.com/software/security/best-antivirus-software/how-infected-are-we.html>>. Acesso em 9 de abril de 2017.

CNN, *Nearly 1 million new malware threats released every day.* Disponível em:

<<https://www.usnews.com/news/articles/2014/06/09/study-hackers-cost-more-than-445-billion-annually>>. Acesso em 8 de abril de 2017.

U.S. News, *Study: Hackers Cost More Than \$445 Billion Annually.* Disponível

em: <<http://money.cnn.com/2015/04/14/technology/security/cyber-attack-hacks-security/>>. Acesso em 8 de abril de 2017.

DEFINIÇÕES E ABREVIATURAS

Artefato Computacional – sistema de *software* ou de *hardware*, ou ainda uma combinação dos dois, que será desenvolvido com vistas à solução de um ou mais problemas identificados em um ambiente de interesse.

DII – Biblioteca de linkagem dinâmica.

Malware – Programa que danifica ou faz ações indesejadas no computador.

Relatório de Atividades – conjunto de lançamentos de eventos que ocorrem no decorrer do TCC, sempre que ocorrer: término previsto, atraso, antecipação ou cancelamento, considerando o início e o fim de uma atividade. Um lançamento é constituído: da identificação da atividade, sua descrição, sua data de início e sua data de fim, conforme proposto no Cronograma. Segue o status (término conforme cronograma, atraso, antecipação ou cancelamento). Caso o término não seja o esperado, devem ser incluídos: justificativa (o porquê do evento); encaminhamento (alteração do cronograma – pode ser apenas a proposta de uma nova data de fim, por conta de um atraso, ou o cancelamento da atividade); e consequência (análise e alteração das atividades ainda não encerradas por conta do encaminhamento decidido). Esses lançamentos serão úteis para a escrita da monografia.